

智能视觉感知软件的对抗鲁棒性测试与自动化评估

方向 8-小组 1

摘要: 深度神经网络在图像分类等视觉感知任务中展现出卓越性能,然而其对微小的对抗扰动极其脆弱,存在"高精度、高脆弱"的核心悖论.针对智能视觉感知软件的对抗鲁棒性评估问题,本文以基于 ResNet-18 架构的 36 类果蔬识别系统为实验载体,构建了一套完整的对抗鲁棒性测试与自动化评估框架.首先,实现了 FGSM 与 PGD 两种主流对抗攻击算法,在 L_∞ 范数约束下系统测试了不同扰动强度下普通模型的性能衰减规律;实验结果表明,PGD 攻击在 $\epsilon=0.03$ 时即可使普通模型准确率从 93.92%降至 0%,而 FGSM 攻击在 $\epsilon=0.01$ 时准确率已降至 18.78%,揭示了迭代攻击更强的破坏力.其次,基于自动化评估框架,构建了 adversarial_evaluate 模块,实现批量对抗样本生成、核心指标自动统计与可视化报告输出,包含模型衰减曲线与类别混淆热力图.最后,引入对抗训练防御机制,在训练循环中实时生成 PGD 对抗样本进行鲁棒性优化;实验验证,对抗训练后的鲁棒模型在 FGSM($\epsilon=0.01$)攻击下准确率从 18.78%提升至 70.99%,在 PGD($\epsilon=0.01$)攻击下准确率从 2.21%提升至 70.44%,显著增强了模型的对抗鲁棒性,但清洁准确率从 93.92%下降至 80.66%,体现了鲁棒性与精度的 Trade-off 效应.

关键词: 对抗鲁棒性;对抗攻击;对抗训练;ResNet;自动化评估;果蔬识别

Adversarial Robustness Testing and Automated Evaluation for Intelligent Visual Perception Software

DIRECTION8-GROUP1

Abstract: Deep neural networks exhibit remarkable performance in visual perception tasks such as image classification, yet they are extremely vulnerable to imperceptible adversarial perturbations, revealing the core paradox of "high accuracy, high fragility". To address the adversarial robustness evaluation problem of intelligent visual perception software, this paper constructs a comprehensive adversarial robustness testing and automated evaluation framework using a ResNet-18 based 36-class fruit and vegetable recognition system as the experimental carrier. First, two mainstream adversarial attack algorithms, FGSM and PGD, are implemented to systematically test the performance degradation of the standard model under different perturbation strengths within the L_∞ norm constraint. Experimental results show that PGD attack reduces the standard model accuracy from 93.92% to 0% at $\epsilon=0.03$, while FGSM attack reduces accuracy to 18.78% at $\epsilon=0.01$, revealing the stronger destructive power of iterative attacks. Second, an automated evaluation framework is constructed with an adversarial_evaluate module that enables batch adversarial sample generation, automatic calculation of core metrics, and visualization report output including model degradation curves and class confusion heatmaps. Finally, an adversarial training defense mechanism is introduced, which generates PGD adversarial samples in real-time during the training loop for robustness optimization. Experiments verify that the adversarially trained robust model improves accuracy from 18.78% to 70.99% under FGSM ($\epsilon=0.01$) attack and from 2.21% to 70.44% under PGD ($\epsilon=0.01$) attack, significantly enhancing adversarial robustness, though clean accuracy decreases from 93.92% to 80.66%, demonstrating the robustness-accuracy trade-off effect.

Key words: adversarial robustness; adversarial attack; adversarial training; ResNet; automated evaluation; fruit recognition

1 引言

深度神经网络在图像分类、目标检测等视觉感知任务中取得了突破性进展,已被广泛应用于自动驾驶、人脸识别、智能收银等安全敏感场景.然而,Szegedy 等人^[1]的开创性研究发现,通过对原始图像添加人眼不可感知的微小扰动即可生成对抗样本,导致深度学习模型产生完全错误的识别结果,揭示了深度神经网络普遍存在的"高精度、高脆弱"核心悖论.在自动驾驶场景中,微小的对抗扰动可使系统将"停车让行"标志误判为"限速"标志,引发重大交通安全事故;在人脸识别领域,攻击者可通过简易手段伪造身份信息,造成个人隐私泄露与信息安全隐患;在智能收银场景中,对抗贴纸类攻击会直接导致商家经济损失.因此,深入研究视觉模型的对抗鲁棒性,构建高效的攻击防御机制,对保障智能视觉系统的安全稳定应用具有重要的现实意义与工程价值.

当前,对抗鲁棒性研究主要集中在两个方面:一是攻击侧,即研究如何更有效地生成对抗样本以暴露模型脆弱性;二是防御侧,即研究如何提升模型对对抗扰动的抵抗能力.在攻击侧,Goodfellow 等人^[2]提出的 FGSM 快速梯度符号攻击奠定了单步攻击的基础,Madry 等人^[3]提出的 PGD 投影梯度下降攻击成为迭代攻击的标准基准方法.在防御侧,对抗训练(adversarial training)被公认为最有效的防御策略之一,其核心思想是在训练过程中引入对抗样本,使模型在学习清洁数据特征的同时增强对对抗扰动的鲁棒性.然而,对抗训练通常以牺牲清洁样本上的准确率为代价,即存在鲁棒性与精度的 Trade-off 效应.

尽管对抗鲁棒性研究已取得丰富成果,但在实际工程应用中仍面临以下挑战:(1) 缺乏标准化的自动化评估工具,多数研究采用手动调参、单点测试的方式,难以全面刻画模型在不同攻击强度下的鲁棒性边界;(2) 鲁棒性评估指标单一,通常仅报告特定攻击设置下的准确率,缺乏模型衰减曲线、类别混淆分析等多维度评估;(3) 防御策略的验证不够系统,缺少清洁准确率与对抗准确

率的综合对比分析.针对上述问题,本文以基于 ResNet-18 架构的 36 类果蔬识别系统为实验载体,构建了一套完整的对抗鲁棒性测试与自动化评估框架,主要贡献如下:

(1) 构建了对抗鲁棒性自动化评估框架,实现了 FGSM 与 PGD 两种主流攻击算法的批量测试,在 L_∞ 范数约束下自动遍历不同扰动强度,生成包含模型衰减曲线与类别混淆热力图的标准化质量报告.

(2) 系统测试了普通模型在 FGSM 与 PGD 攻击下的性能衰减规律,实验发现 PGD 攻击的破坏力远强于 FGSM 攻击,在 $\epsilon=0.03$ 时即可使模型准确率完全崩溃至 0%.

(3) 引入对抗训练防御机制并进行了系统验证,对抗训练后的鲁棒模型在弱扰动下($\epsilon=0.01$)的对抗准确率显著提升,同时定量分析了鲁棒性与精度的 Trade-off 效应.

2 相关工作

2.1 对抗攻击方法

对抗样本是指在原始正常图像中添加人眼不可感知的微小噪声,即可导致深度学习模型产生错误识别结果的特殊样本.Goodfellow 等人^[2]在 ICLR 2015 提出的 FGSM(Fast Gradient Sign Method)快速梯度符号攻击是对抗样本领域的奠基性工作.FGSM 通过计算损失函数对输入数据 x 的梯度,提取梯度符号方向 $\text{sign}(\nabla_x L(\theta, x, y))$,乘以微小扰动系数 ϵ 后叠加至原图,即可快速生成对抗样本.该研究证明了神经网络易受对抗攻击的本质是高维空间中的线性特性,为对抗样本的生成机理研究奠定了理论基础.

Madry 等人^[3]在 ICLR 2018 提出的 PGD(Projected Gradient Descent)投影梯度下降攻击是迭代式增强攻击算法的核心代表.PGD 通过多次迭代优化扰动并将其约束在 L_∞ 范数球的合法范围内,其迭代公式为:

$$x^{t+1} = \Pi_{x+S} \left(x^t + \alpha \cdot \text{sign}(\nabla_x L(\theta, x, y)) \right)$$

其中 α 为步长, Π 为投影操作.由于 PGD 攻击能够突破常规防御机制(如梯度掩盖、输入变换等),已被广泛接受为深度学习模型对抗鲁棒性评估的标准基准方法.理论分析表明,在特定条件下,PGD 攻击生成的对抗样本近似于一阶最优攻击.

2.2 鲁棒性评估基准

虽然 PGD 攻击奠定了迭代攻击的基础,但单一攻击手段往往因超参数敏感或模型存在的梯度掩盖现象导致鲁棒性被高估.为此,Croce 等^[4]在 NeurIPS 2020 提出了 RobustBench 标准化基准,该工作引入了集成攻击工具 AutoAttack^[5],通过组合多种白盒与黑盒攻击(如 FAB 和 Square Attack),有效避免了手动调参的过程,为模型安全性提供了真值评估标准.RobustBench 的核心评估指标为 AutoAttack 下的准确率,该指标能够在不依赖特定攻击超参数的情况下给出模型鲁棒性的可靠上界估计.本研究参考 RobustBench 的标准化评估理念,构建自动化评估流水线,以 PGD 攻击下的模型准确率作为核心评估指标,并辅以 FGSM 攻击进行对比分析.

2.3 对抗训练防御

对抗训练是目前最有效的经验性防御策略,其核心思想是通过在最坏情况扰动下最小化训练损失来增强模型鲁棒性,优化目标可表述为: $\min_{\theta} \mathbb{E}_{(x,y) \sim D} \left[\max_{\|\delta\| \leq \epsilon} L(\theta, x + \delta, y) \right]$.Madry 等人^[3]证明,PGD 攻击生成的对抗样本可以作为内层最大化问题的近似解,因此 PGD 对抗训练成为最广泛使用的对抗训练方案.然而,对抗训练面临两个主要挑战:(1)计算开销显著增加,每次迭代需额外执行 PGD 攻击生成对抗样本;(2)清洁准确率与对抗准确率之间存在 Trade-off,即鲁棒性的提升通常以牺牲清洁样本上的分类精度为代价.本文将在实验部分定量分析这一 Trade-off 效应.

3 方法框架

3.1 基础模型

本研究选取基于 ResNet-18 架构的果蔬识别系统作为实验载体.ResNet 由 He 等人^[6]于 CVPR 2016 提出,其核心创新为引入残差连接结构,通过捷径支路实现跨层信息传递,有效解决了深层神经网络训练中的梯度消失问题.ResNet-18 作为轻量化残差网络,包含 18 个带权重的层(17 个卷积层+1 个全连接层),兼顾了模型深度与分类性能,是工业界与学术界广泛使用的 backbone 网络.实

验采用的果蔬识别系统支持 36 类日常果蔬(苹果、香蕉、生姜等)的多类别图像分类,集成完整的训练循环、验证逻辑,搭载 TensorBoard 可视化监控模块,支持模型权重保存、加载与断点续训。

3.2 对抗攻击实现

本研究选用 TorchAttacks 作为核心攻击库,该工具轻量化、易集成,封装了 FGSM、PGD 等主流对抗攻击算法.攻击在 L_{∞} 范数约束下进行,扰动强度 ϵ 设置为{0.01, 0.03, 0.05, 0.08, 0.1}五个梯度级别,以系统刻画模型鲁棒性随扰动强度的变化规律.具体攻击配置如下:(1) FGSM 攻击:单步攻击,扰动方向为损失函数梯度的符号方向,扰动大小由 ϵ 控制,生成速度快但攻击强度有限.(2) PGD 攻击:迭代攻击,步长 $\alpha=0.007$,迭代步数 $K=40$,每步将扰动投影回 L_{∞} 范数球内,攻击强度显著高于 FGSM,是鲁棒性评估的标准基准方法.

3.3 自动化评估框架

参考 RobustBench 的标准化评估理念,本研究在原有的 evaluate 函数基础上新增 adversarial_evaluate 模块,构建自动化评估框架.框架的核心工作流程包括:(1) 攻击参数配置:自动遍历 ϵ 在 0~0.1 区间内的不同扰动强度,对 FGSM 和 PGD 两种攻击算法分别配置;(2) 批量对抗样本生成与测试:针对每个(攻击算法, ϵ)组合,自动生成对抗样本并计算模型准确率与攻击成功率;(3) 指标统计与报告生成:自动汇总实验数据,生成标准化的模型质量报告,包含模型衰减曲线(展示准确率随 ϵ 增加的下降速度)和类别混淆热力图(定量分析易混淆的果蔬类别).评估指标主要包括:清洁准确率(Clean Accuracy)、对抗准确率(Adversarial Accuracy)和攻击成功率(Attack Success Rate, ASR),其中 $ASR=1-\text{对抗准确率}/\text{清洁准确率}$.

3.4 对抗训练防御

为提升模型的对抗鲁棒性,本研究引入对抗训练机制,优化原有的仅使用原始图像的训练流程.对抗训练的核心过程为:在每个训练批次中,对当前 batch 的清洁样本执行 PGD 攻击生成对抗样本,将对抗样本与清洁样本混合后进行模型参数更新.对抗训练的损失函数为: $L_{adv} = \lambda \cdot L_{clean} + (1 - \lambda) \cdot L_{pgd}$, 其中 L_{clean} 为清洁样本上的交叉熵损失, L_{pgd} 为 PGD 对抗样本上的交叉熵损失, λ 为混合系数.本研究采用 $\lambda=0.5$ 的等权混合策略,PGD 攻击参数设置为 $\epsilon=0.03$,步长 $\alpha=0.007$,迭代步数 $K=7$ (训练时使用较少迭代步数以平衡计算开销).训练完成后,同样使用自动化评估框架对鲁棒模型进行全面评估,并与普通模型进行系统对比.

4 实验与分析

4.1 实验设置

实验环境:操作系统 Windows 11,深度学习框架 PyTorch,攻击库 TorchAttacks,图像预处理库 TorchVision,数值计算库 NumPy,可视化库 Matplotlib.数据集:采用 Fruit-360 果蔬数据集的子集,包含 36 类果蔬共计 362 张测试图像.模型:ResNet-18,普通模型训练 20 个 epoch,对抗训练模型采用 PGD 对抗训练策略.攻击算法:FGSM 与 PGD,扰动强度 $\epsilon \in \{0.01, 0.03, 0.05, 0.08, 0.1\}$,PGD 步长 $\alpha=0.007$,迭代步数 $K=40$.

4.2 普通模型鲁棒性评估

表 1 展示了普通 ResNet-18 模型在清洁样本与不同对抗攻击设置下的测试结果.该模型在清洁样本上取得了 93.92%的准确率,表现出良好的基准分类性能.然而,在对抗攻击下模型的性能急剧下降:

表 1 普通模型在不同攻击设置下的测试结果

攻击算法	扰动强度 ϵ	准确率 (%)	攻击成功率 ASR (%)	正确/总数
Clean	0	93.92	0	340/362
FGSM	0.01	18.78	75.14	68/362
FGSM	0.03	12.43	81.49	45/362
FGSM	0.05	10.77	83.15	39/362
FGSM	0.08	11.60	82.32	42/362
FGSM	0.10	11.33	82.60	41/362
PGD	0.01	2.21	91.71	8/362
PGD	0.03	0.00	93.92	0/362
PGD	0.05	0.00	93.92	0/362
PGD	0.08	0.00	93.92	0/362
PGD	0.10	0.00	93.92	0/362

从表 1 可以得出以下关键发现:(1) FGSM 攻击下,模型准确率在 $\epsilon=0.01$ 时即从 93.92%骤降至 18.78%,降幅达 75.14 个百分点,随着 ϵ 继续增大,准确率缓慢下降并趋于平稳(约 10%~12%),表明 FGSM 单步攻击的扰动强度存在上限.(2) PGD 攻击的破坏力远强于 FGSM,在 $\epsilon=0.01$ 时准确率已降至 2.21%,在 $\epsilon \geq 0.03$ 时准确率完全崩溃至 0%,攻击成功率高达 93.92%.这验证了 PGD 作为迭代攻击在突破模型防御方面的显著优势,也说明普通 ResNet-18 模型几乎不具备对抗鲁棒性.

4.2.1 普通模型训练过程




图 1 普通模型训练损失曲线




图 2 普通模型训练/验证准确率曲线




图3 普通模型 Top-1 测试准确率




图4 普通模型 Top-5 测试准确率




图5 普通模型测试损失曲线

4.2.2 普通模型混淆矩阵分析

图 6 至图 12 分别展示了普通模型在清洁样本及不同 PGD 攻击强度下的类别混淆热力图.清洁样本下模型能够正确分类绝大多数样本,但随着 PGD 攻击扰动强度的增加,混淆矩阵逐渐从对角占优退化为均匀分布,表明模型的判别能力被完全破坏.




图 6 普通模型—清洁样本混淆矩阵




图 7 普通模型—PGD 攻击($\epsilon=0.01$)混淆矩阵




图 8 普通模型—PGD 攻击($\epsilon=0.03$)混淆矩阵




图 9 普通模型—PGD 攻击($\epsilon=0.05$)混淆矩阵




图 10 普通模型—PGD 攻击($\epsilon=0.08$)混淆矩阵




图 11 普通模型—PGD 攻击($\epsilon=0.1$)混淆矩阵

4.3 鲁棒模型评估与对比分析

表 2 展示了对经过对抗训练后的鲁棒 ResNet-18 模型在清洁样本与不同对抗攻击设置下的测试结果.与普通模型相比,鲁棒模型在对抗攻击下的性能有显著提升:

表 2 对抗训练鲁棒模型在不同攻击设置下的测试结果

攻击算法	扰动强度 ϵ	准确率(%)	攻击成功率 ASR(%)	正确/总数
Clean	0	80.66	0	292/362
FGSM	0.01	70.99	9.67	257/362
FGSM	0.03	52.76	27.90	191/362
FGSM	0.05	37.29	43.37	135/362
FGSM	0.08	22.93	57.73	83/362
FGSM	0.10	17.13	63.54	62/362
PGD	0.01	70.44	10.22	255/362
PGD	0.03	44.20	36.46	160/362
PGD	0.05	22.38	58.29	81/362
PGD	0.08	5.25	75.41	19/362
PGD	0.10	1.93	78.73	7/362

表 3 普通模型与鲁棒模型的核心指标对比

评估指标	普通模型	鲁棒模型	变化
清洁准确率(%)	93.92	80.66	-13.26
FGSM($\epsilon=0.01$)准确率(%)	18.78	70.99	+52.21
PGD($\epsilon=0.01$)准确率(%)	2.21	70.44	+68.23
PGD($\epsilon=0.03$)准确率(%)	0.00	44.20	+44.20

从表 3 的对比分析可以得出以下结论:(1) 对抗训练显著提升了模型的对抗鲁棒性:在 FGSM($\epsilon=0.01$)攻击下,鲁棒模型准确率从 18.78%提升至 70.99%,提升幅度达 52.21 个百分点;在 PGD($\epsilon=0.01$)攻击下,准确率从 2.21%提升至 70.44%,提升幅度达 68.23 个百分点;在 PGD($\epsilon=0.03$)攻击下,普通模型准确率已完全崩溃至 0%,而鲁棒模型仍保持 44.20%的准确率,体现了对抗训练的显著防御效果.(2) 对抗训练存在鲁棒性与精度的 Trade-off:鲁棒模型的清洁准确率从 93.92%下降至 80.66%,降幅为 13.26 个百分点.这一现象与已有理论分析一致,表明模型在学习抵抗对抗扰动的同时,部分清洁样本的决策边界发生了偏移,导致清洁分类精度下降.(3) 鲁棒模型在高扰动强度下仍会失效:在 PGD($\epsilon=0.1$)攻击下,鲁棒模型准确率降至 1.93%,说明对抗训练主要在训练时设定的扰动范围内提供有效保护,超出训练扰动范围的攻击仍可能导致模型失效.

4.3.1 鲁棒模型准确率衰减曲线

图 12 展示了对抗训练鲁棒模型在不同攻击强度下的准确率衰减曲线.与普通模型的急剧衰减不同,鲁棒模型的准确率随扰动强度的增加呈现较为平缓的下降趋势,体现了对抗训练赋予模型的梯度平滑特性.




图 12 鲁棒模型准确率衰减曲线

4.3.2 鲁棒模型混淆矩阵分析

图 13 至图 18 分别展示了鲁棒模型在清洁样本及不同 PGD 攻击强度下的类别混淆热力图.与普通模型在 PGD 攻击下迅速退化为均匀分布不同,鲁棒模型在弱至中等扰动强度下仍能保持较好的对角占优特性,主要混淆集中在视觉相似的类别之间(如番茄与辣椒、甜椒与辣椒等),表明对抗训练有效维持了模型的语义特征提取能力.仅在强扰动($\epsilon \geq 0.08$)下,混淆矩阵才开始出现明显的退化趋势.




图 13 鲁棒模型—清洁样本混淆矩阵




图 14 鲁棒模型—PGD 攻击($\epsilon=0.01$)混淆矩阵




图 15 鲁棒模型—PGD 攻击($\epsilon=0.03$)混淆矩阵




图 16 鲁棒模型—PGD 攻击($\epsilon=0.05$)混淆矩阵




图 17 鲁棒模型—PGD 攻击($\epsilon=0.08$)混淆矩阵




图 18 鲁棒模型—PGD 攻击($\epsilon=0.1$)混淆矩阵

4.4 类别混淆分析

通过类别混淆热力图分析,可以定量识别模型在对抗攻击下易混淆的果蔬类别.普通模型在清洁样本上的混淆矩阵显示,主要混淆对包括:番茄与辣椒(视觉相似性高)、甜椒与辣椒(形状与颜色接近)、萝卜与甜薯(形态相似).在 PGD 攻击下,模型的混淆模式发生显著变化,原本正确分类的样本被随机分散至各类别,呈现出近乎均匀的混淆分布,表明 PGD 攻击已完全破坏了模型的特

征提取能力.鲁棒模型在对抗攻击下的混淆模式则相对集中,主要混淆仍发生在视觉相似类别之间,说明对抗训练有效维持了模型的语义特征提取能力.

4.5 自动化评估框架有效性验证

自动化评估框架的有效性体现在以下方面:(1) 效率提升:框架自动遍历 5 个扰动强度与 2 种攻击算法的 10 种组合,无需手动逐一配置攻击参数与记录结果,评估效率显著提升.(2) 标准化输出:框架统一输出准确率、攻击成功率、混淆矩阵等核心指标,生成模型衰减曲线与类别混淆热力图,便于不同模型间的横向对比.(3) 可扩展性:框架采用模块化设计,可方便地添加新的攻击算法(如 CW 攻击、AutoAttack)或新的评估指标,具有良好的可扩展性.

5 结论与展望

本文针对智能视觉感知软件的对抗鲁棒性评估问题,以基于 ResNet-18 架构的 36 类果蔬识别系统为实验载体,构建了一套完整的对抗鲁棒性测试与自动化评估框架,主要结论如下:

(1) 普通 ResNet-18 模型几乎不具备对抗鲁棒性:PGD 攻击在 $\epsilon=0.03$ 时即可使模型准确率从 93.92% 完全崩溃至 0%,FGSM 攻击在 $\epsilon=0.01$ 时准确率已降至 18.78%.迭代攻击(PGD)的破坏力远强于单步攻击(FGSM),是更可靠的鲁棒性评估基准.

(2) 对抗训练是有效的防御策略:在弱扰动($\epsilon=0.01$)下,鲁棒模型的 FGSM 准确率提升至 70.99%,PGD 准确率提升至 70.44%;在中扰动($\epsilon=0.03$)下,PGD 准确率仍保持 44.20%,而普通模型已完全失效.但对抗训练存在鲁棒性与精度的 Trade-off,清洁准确率下降 13.26 个百分点.

(3) 自动化评估框架有效提升了鲁棒性测试的效率与标准化程度,支持批量攻击参数遍历、多维度指标统计与可视化报告生成,为模型安全性评估提供了系统性工具支持.

未来工作将从以下方向展开:(1) 引入 AutoAttack 等集成攻击工具,进一步提升鲁棒性评估的可靠性与全面性;(2) 探索自适应对抗训练、特征去噪等先进防御策略,在保持清洁准确率的同时提升对抗鲁棒性;(3) 将评估框架扩展至目标检测、语义分割等更复杂的视觉感知任务,验证框架的通用性.

References

- [1] Szegedy C, Zaremba W, Sutskever I, et al. Intriguing properties of neural networks[C]//Proceedings of the International Conference on Learning Representations. 2014.
- [2] Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples[J]. arXiv preprint arXiv:1412.6572, 2015.
- [3] Madry A, Makelov A, Schmidt L, et al. Towards deep learning models resistant to adversarial attacks[J]. arXiv preprint arXiv:1706.06083, 2018.
- [4] Croce F, Andriushchenko M, Schwag V, et al. RobustBench: a standardized adversarial robustness benchmark[C]//Advances in Neural Information Processing Systems. 2020, 33: 19866-19881.
- [5] Croce F, Hein M. Reliable evaluation of adversarial robustness with an ensemble of diverse parameter-free attacks[C]//Proceedings of the International Conference on Machine Learning. 2020: 2206-2216.
- [6] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [7] Carlini N, Wagner D. Towards evaluating the robustness of neural networks[C]//Proceedings of the IEEE Symposium on Security and Privacy. 2017: 39-57.
- [8] Wong E, Kolter Z. Provable defenses against adversarial examples via the convex outer adversarial polytope[C]//Proceedings of the International Conference on Machine Learning. 2018: 5286-5295.
- [9] Zhang H, Yu Y, Jia M, et al. Theoretically grounded transfer learning from deep to model-robust encodings[C]//Advances in Neural Information Processing Systems. 2019.
- [10] Rice L, Wong E, Kolter Z. Overfitting in adversarially robust deep learning[C]//Proceedings of the International Conference on Machine Learning. 2020: 8093-8104.