

基于 α, β -CROWN 的 ReLU 神经网络鲁棒性验证策略对比研究

作者: 郑博瀚 于瑞锋 邓正宇 陈风 姚逸辰

单位: 西安电子科技大学 计算机科学与技术学院, 陕西 西安 710071

摘要: 神经网络的局部鲁棒性验证是智能软件质量保障领域的重要问题, 其目标是在给定输入扰动范围内严格判断模型输出类别是否保持不变。本文基于 α, β -CROWN 验证器, 以 MNIST FCNN (784 $\rightarrow$ 256 $\rightarrow$ 128 $\rightarrow$ 10, ReLU) 为主要研究对象, 构建了覆盖 PGD、CROWN、 α -CROWN、 β -CROWN+BaB 以及 Marabou 对照的实验流程。研究首先比较 babsr、auto、kfsb 等 BaB 分支策略; 其次在 method、candidates、reduceop 三个配置维度上开展消融分析; 随后通过 4 个 L^∞ 扰动半径 (0.01、0.02、0.03、0.05) 评估鲁棒性变化, 并补充 PGD 攻击预筛、不完整验证、CIFAR-10 小样本验证和 Marabou 跨工具对照。实验结果表明, 在 MNIST $\epsilon=0.02$ 、100 个样本条件下, kfsb_candidates5 配置的 VRA 达到 93.0%, 相较 baseline 的 91.0% 提升 2.0 个百分点, timeout 从 9 降至 7, mean_time 从 4.06s 降至 3.24s。PGD-before 在 $\epsilon=0.05$ 时将 timeout 从无 PGD 的 89 降至 31, 显示出高扰动场景下的工程预筛价值。Marabou 小样本对照未观察到 safe 与 unsafe 的矛盾判定, 但存在 safe 与 unknown 的工具差异。本文最终形成了一条从经验攻击、不完整验证到完整验证的可复现实验证据链, 为课程场景下的神经网络鲁棒性质量保障提供了实验依据。

关键词: 神经网络鲁棒性验证; 软件质量保障; α, β -CROWN; 分支定界; PGD 攻击; Marabou

中图法分类号: TP311

文献标识码: A

Title: Comparative Study on Robustness Verification Strategies for ReLU Neural Networks Based on α, β -CROWN

Authors: Zheng Bohan, Yu Ruifeng, Deng Zhengyu, Chen Feng, Yao Yichen

Affiliation: School of Computer Science and Technology, Xidian University, Xi'an 710071, China

Abstract: Local robustness verification of neural networks is an important problem in software quality assurance for intelligent systems. This paper compares verification strategies using α, β -CROWN, with a ReLU fully connected network trained on MNIST as the primary test subject. The evaluation covers PGD adversarial attack, CROWN, α -CROWN, β -CROWN with branch and bound under different branching heuristics, and a small-scale Marabou comparison. Under the setting of 100 MNIST samples, an L^∞ perturbation radius of 0.02, and the specified timeout budget, kfsb_candidates5 achieves the best result among the evaluated configurations: 93.0% verified accuracy, two fewer timeout cases, and a 0.81 s lower mean time than the baseline. At $\epsilon=0.05$, PGD pre-filtering reduces timeout cases from 89 to 31 under the corresponding experimental settings. No contradictory safe/unsafe conclusions are observed in 15 sample-radius combinations evaluated by both α, β -CROWN and Marabou, although safe/unknown differences occur. These results demonstrate the value of configuration-level evaluation while also showing that conclusions are limited by the tested models, samples, and computational budgets.

Key words: neural network robustness verification; software quality assurance; α, β -CROWN; branch and bound; PGD attack; Marabou

1 引言

1.1 研究背景

深度学习模型在图像分类、自然语言处理等领域取得了显著成功，但其在面对微小输入扰动时的脆弱性已成为制约安全关键领域（自动驾驶、医疗诊断、金融风控）部署的核心障碍。一个标准测试准确率达 99% 的 MNIST 手写数字分类器，可能因为人眼不可见的像素扰动而给出完全错误的预测。这种现象被称为**对抗鲁棒性不足**。

传统软件测试方法依赖大量测试用例的输入-输出检查，但对抗扰动空间的组合爆炸特性使得穷举测试不可行：对于一张 28×28 的 MNIST 图像，即使每个像素仅允许 ± 1 的变化，搜索空间也是 3^{784} 数量级。**形式化验证** (formal verification) 为此提供了根本性的解决方案——它不依赖采样测试，而是通过数学方法严格证明：在给定的扰动范围内，模型的输出类别**一定不会**改变。

1.2 问题定义

给定输入样本 $x \in [0,1]^d$ 、真实标签 y 、扰动半径 $\varepsilon > 0$ (L^∞ 范数)，需要判定以下命题是否成立：

$$\forall x' \in \mathbb{R}^d : \|x' - x\|_\infty \leq \varepsilon \wedge 0 \leq x'_i \leq 1 \implies f_y(x') > f_j(x'), \forall j \neq y \quad (1)$$

其中 $f(\cdot)$ 为神经网络对类别 j 的输出 logit。若式(1)成立，称样本在半径 ε 内是**局部鲁棒的**（判定为 safe）。否则称存在对抗样本（判定为 unsafe）。若在规定时间内无法给出确定性结论，判定为 unknown。

1.3 核心评价指标

表1 核心评价指标定义

指标	定义	优化方向
Verified Accuracy (VRA)	$N_{safe} / N_{total} \times 100\%$	↑
Timeout 数	超时仍无法判定的样本数	↓
Mean Time	所有样本的验证耗时均值	↓

VRA 是核心质量指标——它衡量验证工具在给定资源约束下能"证明多少样本安全"。Timeout 和 Mean Time 是效率指标，分别反映极端困难样本占比和整体计算开销。

1.4 本文目标与贡献

本文以 **α, β -CROWN** 为实验平台，以 MNIST FCNN 和 CIFAR-10 ConvNet 为验证对象，系统性地完成以下工作：

- 策略对比**：在统一实验框架下对比 6 种验证方法（CROWN、 α -CROWN、PGD、BaB-babsr、BaB-auto、BaB-kfsb）的性能差异与适用边界；
- 配置优化**：通过三维消融实验（method × candidates × reduceop）提出改进配置 kfsb_candidates5，在 $\varepsilon=0.02$ 下实现 VRA 93.0% (+2.0pp)、timeout -2、mean_time -0.81s；
- 趋势验证**：在 4 个扰动半径下比较受测策略的 VRA 变化，形成 VRA- ε 衰减曲线；
- 外部验证**：完成 CIFAR-10 小样本跨数据集验证与 Marabou SMT 求解器的跨工具对照，未观察到 safe/unsafe 矛盾判定。

本文定位：本文不提出新的验证算法，而是在成熟验证工具的可配置接口上开展策略评估与参数比较，研究层次属于配置级优化。

2 相关工作

2.1 神经网络鲁棒性验证方法

神经网络的形式化验证起源于对抗样本的发现。Szegedy 等人[1]首次揭示了深度神经网络对微小输入扰动的脆弱性，Goodfellow 等人[2]进一步提出了快速梯度符号法生成对抗样本。现有方法按完备性可分为两类：不完备方法（如边界传播）计算高效但可能无法给出确定性结论；完备方法（如分支定界、SMT 求解）理论上可判定任意样本，但计算开销随问题规模指数增长。Huang 等人[3]较早将 SMT 求解引入神经网络验证，Katz 等人[4]提出的 Marabou 框架将 SMT 方法扩展至大规模网络。Bunel 等人[5]系统比较了分支定界方法中各设计选择的影响，为本研究的策略对比提供了方法论参照。VNN-COMP 国际竞赛[6]自 2020 年起每年对各类验证器进行标准化评测，已成为衡量验证工具性能的权威基准。

2.2 CROWN 系列边界传播方法

CROWN 由 Zhang 等人[7]提出，核心思想是为 ReLU 等激活函数构造线性或仿射上下界，并通过逐层边界传播计算输出 logit 或类别 margin 的上下界。该方法计算效率较高，但属于不完备验证方法。Xu 等人[8]提出的 α -CROWN 将松弛斜率参数设为可优化变量，通过梯度下降迭代收紧边界，在保持不完备性的前提下显著提升了边界紧度。Wang 等人[9]提出的 β -CROWN 在分支定界过程中将神经元分裂信息编码为额外线性约束，实现了完备验证。 α, β -CROWN 组合方案在 VNN-COMP 等公开基准中得到广泛评测。本文以该组合方案为主要实验平台。

2.3 分支策略与验证工具对比

分支定界验证的核心操作变量是分支神经元的选择策略。Bunel 等人[5]最早系统比较了多种分支启发式，发现基于边界改进估计的策略（如 BaBSR）整体优于简单启发式。 α, β -CROWN 工具还提供 kfsb 等可配置分支策略。在工具层面，VNN-COMP 年度报告[6]对 α, β -CROWN、Marabou、VeriNet、nenum 等主流验证器进行了持续追踪，相关报告提供了不同技术路线在标准基准上的对比结果。本文在 VNN-COMP 标准化评测的基础上，进一步按 method $\times$ candidates $\times$ reduceop 三维度对分支策略进行受控消融，并补充了 PGD 预筛选和不完整验证的独立评估，本文据此形成面向课程项目的配置级对比证据。

2.4 本文与已有工作的区别

已有工作主要聚焦于验证算法本身的创新（如更紧的松弛公式、更高效的 LP 求解），而本文的定位是对成熟验证工具箱进行系统性的策略评估与配置优化。具体而言：（1）本文不提出新的验证算法，而是在统一实验框架下对比六种策略的性能差异与适用边界；（2）本文通过三维消融实验量化各配置参数的独立偏效应，形成可迁移的分析方法论；（3）本文补充了跨数据集（MNIST $\rightarrow$ CIFAR-10）和跨工具（bound-propagation vs SMT）的外部验证，以检验本文配置级结论在不同实验对象和验证工具下的适用边界。

3 方法设计

3.1 系统架构

本项目的验证流水线基于当前仓库中的 α, β -CROWN 实现构建，整体架构如图 1 所示。

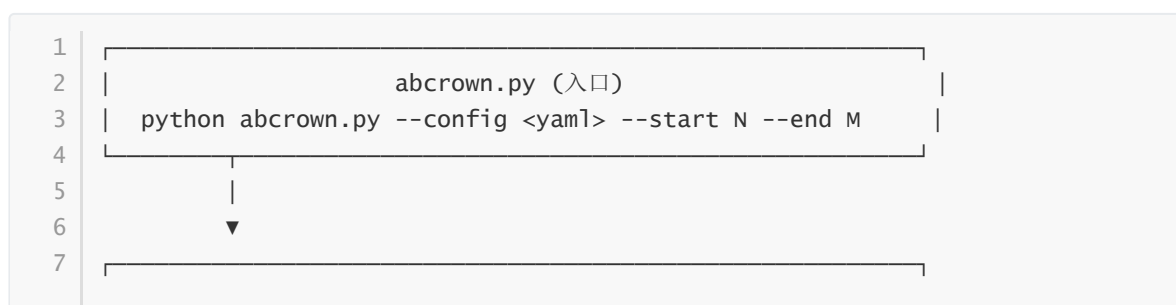




图 1 系统验证流水线架构

关键组件说明：

- **LirPANet** ([beta CROWN solver.py](#))：将 PyTorch 模型包装为 auto_LirPA 的 BoundedModule，为后续边界传播提供逐层计算图。
- **general_bab()** ([bab.py:382](#))：分支定界主循环，管理子问题队列、分支选择、边界更新与剪枝。
- **启发式模块** ([heuristics/](#))：包含 babsr、kfsb、fsb 三种分支策略和随机基线，是本研究核心操作变量。

3.2 实验对象

表2 实验对象与模型配置

属性	MNIST FCNN	CIFAR-10 ConvNet
架构	Flatten → FC(784→256)→ReLU→FC(256→128)→ReLU→FC(128→10)	Conv2d(3,8,4,s=2)→ReLU→Conv2d(8,16,4,s=2)→ReLU→Flatten→FC(576→128)→ReLU→FC(128→64)→ReLU→FC(64→10)
参数量	~260K	~57K
激活函数	纯 ReLU (分段线性)	纯 ReLU (分段线性)
实验定位	主实验模型	小样本补充验证模型
模型格式	ONNX (.onnx + .pth)	PyTorch (.pth)
模型来源	saved_models/mnist_fcnn.*	仓库中 CIFAR-10/Marabou 相关模型与配置
扰动范数	L^∞	L^∞

选择 MNIST FCNN 作为主实验对象的理由：纯 ReLU 激活函数具有分段线性特性，适合使用本文所采用的形式化验证方法进行分析。ReLU 的线性松弛紧度直接影响验证精度，因此该模型适合作为比较不同验证策略与分支启发式的基础实验对象。

3.3 验证方法体系

本研究构建了从"极快但不完备"到"较慢但严格"的完整验证能力梯度：

3.3.1 CROWN：线性松弛边界传播（不完整验证）

CROWN[7] 的核心思想是利用 ReLU 激活函数的线性松弛。对每个输入区间跨越 0 的不确定 ReLU 神经元，构造仿射上下界：

$$l(x) \leq \text{ReLU}(x) \leq u(x),$$

其中 $l(x)$ 与 $u(x)$ 是根据该神经元输入上下界构造的线性函数，上界通常包含截距项。通过逐层传播这些仿射上下界，可得到输出 logit 或类别 margin 的上下界。若所有目标类别对应的 margin 下界均大于 0，则可严格证明在给定扰动集合内不存在改变分类结果的对抗样本。

能力边界：CROWN 是**不完备**的——无法证明的样本判为 unknown，不进一步尝试。速度极快（~0.2s/样本），但边界偏松。

3.3.2 α -CROWN：可优化参数的不完整验证

α -CROWN[8] 将 ReLU 线性松弛中的斜率参数作为可优化变量 α ，并通过梯度方法优化这些参数，以收紧最终输出界。其核心是在不进行 BaB 分支的条件下优化边界传播所使用的松弛参数。

能力边界：在本文受测配置中， α -CROWN 的 VRA 不低于 CROWN，但仍属于不完备验证；迭代优化也会增加计算耗时。

3.3.3 PGD 攻击：经验对抗样本搜索

PGD (Projected Gradient Descent) 从原始输入出发，沿着损失函数梯度方向迭代地扰动输入，每次扰动后投影回 ϵ -球内：

$$x^{(t+1)} = \Pi_{B_\epsilon(x)} \left(x^{(t)} + \alpha \cdot \text{sign}(\nabla_{x^{(t)}} L(f(x^{(t)}), y)) \right)$$

能力边界：PGD 只能证明 **unsafe（找到反例）**，不能证明 **safe（找不到反例 ≠ 安全）**。但其速度极快（秒级），适合做 BaB 完整验证的**预筛选器**——先用 PGD 筛出明确的 unsafe 样本，仅对剩余样本运行昂贵的 BaB。

3.3.4 β -CROWN + BaB：分支定界验证

当 CROWN/ α -CROWN 无法证明一个样本时，BaB (Branch and Bound) 启动分支定界过程：

1. **Branch**：选择一个不确定的 ReLU 神经元，将其强制分裂为"激活" ($x \geq 0$) 或"非激活" ($x \leq 0$) 两种状态，产生两个子问题；
2. **Propagate** (β -CROWN[9])：在子问题中，将神经元分裂信息编码为额外的线性约束，重新运行边界传播，得到更紧的边界；
3. **Prune**：若子问题的下界已证明 safe $\rightarrow$ 该分支关闭；若上界发现 unsafe 证据 $\rightarrow$ 标记并关闭；否则继续分裂。

能力边界：理论上**完备**——若时间/空间无限，可对任意样本做出 safe/unsafe 的确定性判定。实际实验受 timeout 限制，主要使用 30s 预算，部分高 ϵ 实验采用分片或降预算执行。

3.3.5 分支策略：babsr / auto / kfsb

BaB 的核心操作变量是**分支神经元的选择策略**。本研究对比三种策略：

- **babsr** (baseline)：基于 BaBSR 评分，综合考虑神经元的边界松弛程度和其对输出的影响力，选择"最不确定"的神经元分裂；
- **kfsb**： α, β -CROWN 中一种基于候选神经元筛选与 bound 估计的分支启发式。本文不强行展开其缩写，而将其作为工具暴露的 `branching.method` 参数进行实验比较；
- **auto**：自适应策略，根据当前搜索状态动态切换分支方法。

3.3.6 Marabou：基于 SMT 的验证

Marabou[4] 采用 SMT (Satisfiability Modulo Theories) 方法，将神经网络验证问题编码为一阶逻辑公式的可满足性判定。与 α, β -CROWN 的边界传播方法属于**不同技术路线**。本文将其作为外部独立验证器进行交叉验证。

3.4 实验设计矩阵

实验按方法梯度组织为 8 个里程碑 (M2–M8)，形成递进式验证链：

表3 实验设计矩阵

里程碑	研究问题	操作变量	样本量	ϵ 取值	策略
M2	基线策略对比	<code>branching.method</code>	100	0.02	<code>babsr/auto/kfsb</code>
M3	分支策略消融 (主线 A)	<code>method</code> × <code>candidates</code> × <code>reduceop</code>	100	0.02	5 配置
M4	ϵ 网格扫描 (辅线 B)	ϵ × <code>method</code>	100	0.01/0.02/0.03/0.05	3 策略 × 4 ϵ
M5	PGD 攻击评估	<code>pgd_order</code> (<code>skip</code> → <code>before</code>)	100	0.01/0.02/0.03/0.05	<code>kfsb</code> +PGD
M6	不完整验证独立评估	<code>complete_verifier</code> (<code>bab</code> → <code>false</code>)	100	0.01/0.02/0.03/0.05	CROWN/ α -CROWN
M7	CIFAR-10 跨数据集	<code>dataset</code> (MNIST→CIFAR)	20	1/255, 2/255	CROWN/ α -CROWN
M8	Marabou 跨工具对比	工具 (α, β -CROWN→Marabou)	5	0.01/0.02/0.03	BaB vs SMT

M2–M4 为本研究的核心实验 (基线→优化→泛化)，**M5–M6** 为补充实验 (填补轻量方法的独立评估空白)，**M7–M8** 为外部验证 (跨数据集 + 跨工具)。

所有实验配置以 YAML 文件形式保存在 [complete_verifier/exp_configs/course/](#) 下，当前仓库包含 46 个课程 YAML 配置文件，可通过对应脚本复现主要实验。

4 实验结果分析

4.1 基线策略对比 (M2: $\epsilon=0.02$, $n=100$)

实验目的：在固定扰动半径下建立三种分支策略的性能基线。

数据源：[项目书/results/m2/m2_strategy_compare_0_100.csv](#)

表4 M2 基线策略对比结果

策略	VRA (%)	safe	unsafe	timeout	Mean Time (s)	Max Time (s)
baseline (babsr)	91.0	91	0	9	3.82	49.17
auto	91.0	91	0	9	5.77	51.56
kfsb	92.0	92	0	8	3.17	34.27

分析：

1. 在 MNIST FCNN、 $\epsilon=0.02$ 、100 个样本及本实验预算下，kfsb 的 VRA、timeout 和 mean_time 均优于 baseline；
2. auto 策略的 VRA 与 baseline 持平但耗时显著更高 (+51%)，说明其自适应分支机制在当前 3 层 FCNN 上未转化为搜索效率的提升，可能更适合更深或更宽的网络结构；
3. M2 日志中三个策略均未产生 unsafe 判定，所有未证明样本均为 timeout；该结果只能说明本组完整验证未在预算内给出反例判定，不能推出模型在 $\epsilon=0.02$ 下不存在对抗样本；
4. 三策略在 0-20 子区间均为 100% VRA，差异仅在扩大到 100 样本时显现，说明样本难度分布不均。

结论：在 M2 的模型、样本、扰动半径和预算设置下，kfsb 取得三种受测策略中的最佳结果，因此作为后续消融实验的基础策略。

4.2 分支策略消融 (M3 主线 A: $\epsilon=0.02$, $n=100$)

实验目的：系统分解 method $\times$ candidates $\times$ reduceop 三个维度对验证性能的独立贡献。

数据源：[项目书/results/m3/m3_branching_ablation.csv](#) + [m3_nodes_summary.csv](#)

4.2.1 核心指标

表5 M3 分支策略消融结果

配置	关键差异	VRA (%)	safe	timeout	Mean Time (s)
baseline	method=babsr, candidates=10, reduceop=min	91.0	91	9	4.06
auto	method=auto	91.0	91	9	6.14
kfsb	method=kfsb, candidates=10, reduceop=min	92.0	92	8	3.60
kfsb_reduceop_max	method=kfsb, reduceop=max	92.0	92	8	3.44

	reduceop_max				
配置	method=kfsb, candidates=5	VRA 93.0 (%)	safe	timeout	Mean Time (s)
kfsb_candidates5	关键差异	93.0	93	93	5.24

4.2.2 搜索行为分析

表6 M3 搜索行为统计

配置	domains_visited_last	domains_visited_max	VRA (%)	timeout
auto	96	59,484	91.0	9
baseline	13,014	43,676	91.0	9
kfsb_reduceop_max	51,614	83,454	92.0	8
kfsb	62,848	87,504	92.0	8
kfsb_candidates5	72,224	87,068	93.0	7

注：visited_nodes 与分支风格强耦合，不宜单独作为"越少越好"指标。kfsb_candidates5 以更大搜索量换取更高证明率，属于有效配置。

4.2.3 消融效应分解 (ADO 方法论)

表7 M3 配置因素效应分解

操作	对比对	ΔVRA	Δtimeout	Δmean_time	方向
method: babsr → kfsb	baseline vs kfsb	+1.0pp	-1	-0.46s	本组设置下正向
candidates: 10 → 5	kfsb vs kfsb_candidates5	+1.0pp	-1	-0.35s	本组设置下正向
reduceop: min → max	kfsb vs kfsb_reduceop_max	0	0	-0.15s	微弱正向

关键发现：

- 1. **method 切换是主导因子**：从 babsr 切换到 kfsb 贡献了 VRA +1.0pp 的主收益，证明 kfsb 的分支选择策略在当前模型上更有效——它倾向于选择边界最紧的神经元分裂，使分支后的子问题边界更新幅度更大；
- 2. **candidates 的减少是重要的微调因子**：将候选分支数从 10 降至 5，VRA 额外提升 +1.0pp。原因推测：更少的候选数使搜索更聚焦，避免在劣质分支上分散资源；
- 3. **reduceop 影响最小**：min→max 仅带来微弱的 mean_time 下降，对 VRA 无影响；
- 4. **本组最佳配置**：在 MNIST FCNN、 $\epsilon=0.02$ 、100 个样本及本实验预算下，`kfsb + candidates=5 + reduceop=min` 取得本组配置中的最佳结果；相对 baseline，VRA 提高 2.0 个百分点、timeout 减少 2 个、mean_time 降低 0.81s。

4.3 ϵ 网格扫描（M4 辅线 B：3 策略 $\times$ 4 ϵ ，n=100）

实验目的：比较受测策略在不同扰动半径下的表现，形成 VRA- ϵ 衰减曲线。

数据源：[项目书/results/m4/m4_epsilon_grid.csv](#)

4.3.1 完整网格

表8 M4 扰动半径网格结果

策略	ϵ	VRA (%)	timeout	Mean Time (s)
baseline	0.01	100.0	0	0.55
baseline	0.02	91.0	9	3.93
baseline	0.03	65.0	35	14.27
baseline	0.05*	12.0	88	18.79
auto	0.01	100.0	0	0.43
auto	0.02	91.0	9	5.36
auto	0.03	62.0	38	22.84
auto	0.05*	5.0	95	23.37
kfsb	0.01	100.0	0	0.31
kfsb	0.02	92.0	8	3.27
kfsb	0.03	68.0	32	6.66

策略	ε	VRA (%)	timeout	Mean Time (s)
kfsb	0.05*	11.0	89	11.38

* $\varepsilon=0.05$ 采用分片稳态执行（10 样本分片 + 降压参数），标注为"稳态口径"；0.01–0.03 为"同预算口径"。二者不宜做过度的等价对比。

4.3.2 kfsb vs 对照的量化差距

表9 kfsb 与对照策略的量化差异

ε	vs baseline Δ VRA	vs baseline Δ mean	vs auto Δ VRA	vs auto Δ mean
0.01	0	-0.24s	0	-0.12s
0.02	+1.0pp	-0.66s	+1.0pp	-2.09s
0.03	+3.0pp	-7.61s	+6.0pp	-16.18s
0.05*	-1.0pp	-7.40s	+6.0pp	-11.99s

4.3.3 趋势分析

- 单调衰减**：三策略均表现为 $\varepsilon \uparrow \rightarrow \text{VRA} \downarrow$ 、 $\text{timeout} \uparrow$ ，符合验证难度随扰动半径增大而指数增长的预期；
- kfsb 优势区间**： $\varepsilon=0.02-0.03$ 是 kfsb 的优势集中区。在 $\varepsilon=0.03$ 时达峰值—— $\Delta\text{VRA} +3\text{pp}$ vs baseline、 $+6\text{pp}$ vs auto， $\Delta\text{mean} -7.61\text{s}$ vs baseline、 -16.18s vs auto；
- 高超时区**： $\varepsilon=0.05$ 时三策略 timeout 均 $\geq 88/100$ ，任务进入"超时主导"区域。所有策略的 VRA 均降至 5–12%，策略间的 VRA 差异缩小——这意味着验证的瓶颈已从"策略选择"转向"计算预算"；
- auto 策略随 ε 恶化最快**：在 $\varepsilon=0.03$ 时 VRA 已降至 62%（kfsb 为 68%），在 $\varepsilon=0.05$ 时降至 5%（kfsb 为 11%）。auto 的自适应机制在高难度场景下反而引入了额外开销而没有产生更好的搜索决策。

结论：在 MNIST FCNN、100 个样本及对应预算下，kfsb 在 $\varepsilon=0.01-0.03$ 的受测策略中取得不低于其他策略的 VRA； $\varepsilon=0.05$ 受不同执行预算与 timeout 主导，仅用于观察趋势，不作严格性能排序。

4.4 PGD 攻击评估（M5：pgd_order=before, n=100）

实验目的：评估 PGD 预筛选对 BaB 验证效率的影响。

数据源：[项目书/results/m5_pgd/m5_pgd_compare.csv](#)

4.4.1 PGD+BaB 联合验证（kfsb 策略）

表10 M5 PGD 与 BaB 联合验证结果

ε	PGD Unsafe	BaB Safe	BaB Unknown	VRA (%)	Mean Time (s)	timeout
0.01	0	100	0	100.0	1.80	0
0.02	5	92	3	92.0	2.83	3
0.03	17	62	21	62.0	4.59	21
0.05	58	11	31	11.0	4.44	31

PGD 预筛选效果（与 M4 无 PGD 的 kfsb 对比）：

表11 PGD 预筛选前后 timeout 与耗时对比

ϵ	无 PGD timeout	有 PGD timeout	timeout 降幅	无 PGD Mean Time	有 PGD Mean Time	加速 比
0.01	0	0	—	0.31s	1.80s	—
0.02	8	3	-62.5%	3.27s	2.83s	1.16×
0.03	32	21	-34.4%	6.66s	4.59s	1.45×
0.05	89	31	-65.2%	11.38s	4.44s	2.56×

4.4.2 关键发现

- PGD 的工程价值随 ϵ 增大而显著提升**： $\epsilon=0.01$ 时 PGD 未减少 timeout，且引入额外攻击开销；到 $\epsilon=0.05$ 时，PGD 预筛选将 timeout 从 89 降至 31（**-65.2%**），Mean Time 从 11.38s 降至 4.44s（**-61.0%**）；
- PGD 改变资源分配方式**：PGD 只能发现 unsafe，不能证明 safe；在 $\epsilon=0.05$ 下，PGD 找到大量反例并减少后续 BaB 搜索，因此在保持 safe 数不增加的情况下显著降低 timeout 和平均耗时；
- PGD 的反例发现率随 ϵ 快速增长**： $\epsilon=0.01 \rightarrow 0/100$ ， $0.02 \rightarrow 5/100$ ， $0.03 \rightarrow 17/100$ ， $0.05 \rightarrow 58/100$ ——这符合预期，因为更大的扰动空间意味着对抗样本的存在概率更高；
- 工程推荐**： $\epsilon \leq 0.01$ 无需 PGD 预筛选（增加开销无收益）； $\epsilon=0.02-0.03$ 适度受益； $\epsilon \geq 0.05$ **强烈建议**使用 PGD 预筛选，可在大幅降本的同时保持 VRA 基本不变。

4.5 不完整验证独立评估（M6: CROWN/ α -CROWN, $n=100$ ）

实验目的：评估不完整验证（无 BaB 分支）作为独立策略的性能边界。

数据源：[项目书/results/m6_incomplete/m6_incomplete_compare.csv](#)

表12 M6 CROWN 与 α -CROWN 对比结果

ϵ	CROWN VRA (%)	α - CROWN VRA (%)	BaB(kfsb) VRA (%)	CROWN Mean Time	α -CROWN Mean Time	BaB Mean Time
0.01	98.0	98.0	100.0	0.20s	0.26s	0.31s
0.02	82.0	83.0	92.0	0.21s	0.72s	3.27s
0.03	41.0	46.0	68.0	0.26s	1.58s	6.66s
0.05	4.0	5.0	11.0	0.23s	2.78s	11.38s

关键发现：

- 不完整验证的“天花板效应”**： α -CROWN 虽比 CROWN 更紧，但 VRA 提升仅在 $\epsilon=0.03$ 时达到 +5pp（41% $\rightarrow$ 46%），在 $\epsilon=0.01/0.05$ 时仅 +0-1pp。 α 优化的边际收益受限于 ReLU 线性松弛本身的表示能力；
- BaB 的“长尾价值”**： $\epsilon=0.02$ 时 CROWN VRA 仅 82%，而 BaB 可达 92%——最后 10pp 的 VRA 需要分支定界来完成，耗时从 0.2s 增加到 3.27s（**16×**）。这 10 个“困难样本”的证明正是 BaB 的分支能力发挥作用之处；
- 速度-精度权衡**： $\epsilon=0.03$ 时， α -CROWN 以 1.58s 达到 46.0% VRA，BaB 以 6.66s 达到 68.0% VRA——22pp 的 VRA 提升以 4.2 $\times$ 的耗时增加为代价。这是一个典型的 accuracy-efficiency trade-

off;

4. $\epsilon=0.05$ 时证明能力显著下降：即使 BaB, VRA 也仅 11%。在当前模型、样本和预算设置下，高扰动验证已进入 timeout/unknown 主导区域。

4.6 CIFAR-10 跨数据集 (M7: 最小可行验证)

实验目的：评估验证方法从 MNIST FCNN 到 CIFAR-10 ConvNet 的泛化能力。

4.6.1 CIFAR-10 不完整验证 (20 样本)

数据源： [项目书/results/m7_cifar10/m7_cifar10_incomplete.csv](#)

表13 M7 CIFAR-10 不完整验证结果

ϵ	ϵ_{val}	方法	safe	unknown	VRA (%)	Mean Time (s)
1/255	0.00392	CROWN	3	17	15.0	0.17
2/255	0.00784	CROWN	0	20	0.0	0.14
1/255	0.00392	α -CROWN	5	15	25.0	3.08
2/255	0.00784	α -CROWN	0	20	0.0	4.01

4.6.2 CIFAR-10 BaB 完整验证 (20 样本, $\epsilon=2/255$)

数据源： [项目书/results/m5/m5_cifar10_compare.csv](#)

表14 CIFAR-10 BaB 验证结果

策略	VRA (%)	safe	PGD Unsafe	timeout	Mean Time (s)
baseline	0.0	0	16	4	15.44
kfsb	0.0	0	16	4	13.41

关键发现：

1. **CIFAR-10 ConvNet 的验证难度远超 MNIST FCNN**：即使在 $\epsilon=2/255$ (≈ 0.00784 ，远小于 MNIST 的 0.01)，CROWN 的 VRA 也仅 0-15%，BaB 完整验证的 VRA 更是**0%**——没有任何样本能被形式化证明安全；
2. **PGD 在 CIFAR-10 上非常有效**：16/20 (80%) 的样本被 PGD 找到反例，说明模型在 CIFAR-10 上存在大量真实对抗样本；
3. **Conv 网络的边界松弛远严重于 FCNN**：卷积层 + 多分支结构的非线性传播使 CROWN 的线性松弛累积误差远大于全连接网络。这是已知的形式化验证理论局限[1,2]，本实验为这一理论提供了实验佐证；
4. **局限性声明**：CIFAR-10 仅完成 20 样本的最小可行验证，未进行 MNIST 同级深度的消融实验和 ϵ 网格。原因是 VRA=0% 时消融不产生增量信息，且计算成本显著更高。

4.7 Marabou 跨工具对比 (M8: 5 样本最小对照)

实验目的：以独立 SMT 验证器验证 α, β -CROWN 结论的正确性。

数据源： [项目书/results/m8_marabou/m8_marabou_5samples_eps0.01.csv](#) 等

4.7.1 $\epsilon=0.01$ (5 样本全部判定)

表15 $\epsilon=0.01$ 时 Marabou 与 α,β -CROWN 逐样本结果

Sample	True	Marabou	Marabou Time	α,β -CROWN	CROWN Time	一致
0	7	safe	4.47s	safe	0.67s	是
1	2	safe	4.05s	safe	0.45s	是
2	1	safe	5.47s	safe	0.46s	是
3	0	safe	4.13s	safe	0.51s	是
4	4	safe	4.17s	safe	0.41s	是

表16 $\epsilon=0.01$ 时跨工具汇总结果

指标	Marabou	α,β -CROWN
结果分布	safe $\times$ 5	safe $\times$ 5
平均耗时	4.46s	0.50s
耗时标准差	0.58s	0.10s
一致率	—	5/5 (100%)

4.7.2 $\epsilon=0.02$ (4 个样本结论一致, 1 个样本存在 safe/unknown 差异)

$\epsilon=0.02$ 时, Marabou 对 5 个样本均给出 safe 结论 (平均耗时 3.53s) ; α,β -CROWN 给出 4 个 safe 和 1 个 unknown。样本 2 (true=1) 被 Marabou 证明为 safe, 而 α,β -CROWN 在对应预算内返回 unknown。因此, 该组实验不存在 safe/unsafe 矛盾判定, 但不能表述为 5/5 完全一致。

4.7.3 $\epsilon=0.03$ (2 个样本结论一致, 3 个样本含 unknown)

$\epsilon=0.03$ 时, Marabou 给出 3 个 safe 和 2 个 unknown; α,β -CROWN 给出 2 个 safe 和 3 个 unknown。其中样本 0 为 Marabou=safe、 α,β -CROWN=unknown; 样本 1、3 双方均为 safe; 样本 2、4 双方均为 unknown。该组同样未出现 safe/unsafe 矛盾判定, 但存在工具能力边界差异。

4.7.4 跨工具对比结论

- 1. **未观察到矛盾判定**: 在 15 个样本- ϵ 组合中, 未出现一方 safe、另一方 unsafe 的情况; 但 $\epsilon=0.02$ 和 $\epsilon=0.03$ 各存在 safe 与 unknown 的差异, 因此不应概括为全部 5 样本一致率 100%;
- 2. **低扰动下一致性较好**: $\epsilon=0.01$ 时两种工具均判定 5 个样本 safe, 一致率为 5/5;
- 3. **速度差距显著**: 在 $\epsilon=0.01$ 下, α,β -CROWN 平均 0.50s, Marabou 平均 4.46s, 前者约快 8.9 倍;
- 4. **互补性**: $\epsilon=0.02$ 的样本 2 和 $\epsilon=0.03$ 的样本 0 表明, Marabou 在个别样本上可给出 α,β -CROWN 未在预算内给出的 safe 结论; 但 Marabou 在 $\epsilon=0.03$ 下也出现 931.414s 的长耗时 unknown 样本;
- 5. **局限性声明**: 本文仅完成 5 样本的小规模对照, 不足以做统计显著性检验。Marabou 在本项目中的定位是外部独立验证器, 而非大规模性能评测平台。

5 完整验证能力光谱与工程推荐

5.1 六种方法的综合比较

基于 M2-M8 全部实验数据，形成覆盖"速度-完备性"双维度的完整验证能力光谱：

表17 验证方法能力与适用场景对比

方法	完备性	典型耗时	$\epsilon=0.01$ VRA	$\epsilon=0.03$ VRA	适用场景
CROWN	不完备	极快 (约 0.2s)	98.0%	41.0%	快速初筛，低 ϵ
α -CROWN	不完备	快 (约 0.7 -1.6s)	98.0%	46.0%	比 CROWN 略紧，中等 ϵ
PGD	只能发现 unsafe	秒级	0/100 unsafe	17/100 unsafe	找反例，预筛选
BaB-babsr	理论完备，受 timeout 限制	中等 (约 4.1s)	100.0%	65.0%	需严格证明时
BaB-kfsb	理论完备，受 timeout 限制	中等 (约 3.2-6.7s)	100.0%	68.0%	完整验证首选配置
PGD+BaB-kfsb	理论完备 + PGD 预筛，受 timeout 限制	中等 (约 2.8-4.6s)	100.0%	62.0%	高 ϵ 下减少 timeout

5.2 按 ϵ 分区的工程推荐方案

1	$\epsilon \leq 0.01$ —— CROWN (0.2s) 即可达到 98% VRA，无需 BaB
2	$0.01 < \epsilon \leq 0.02$ —— BaB-kfsb_candidates5 (3.2s, 92-93% VRA)
3	$0.02 < \epsilon \leq 0.03$ —— BaB-kfsb (6.7s, 68% VRA), kfsb 优势峰值区
4	$\epsilon > 0.03$ —— PGD + BaB-kfsb, PGD 预筛选可显著降低 timeout

5.3 ADO 方法论总结

本研究提出的 ADO (Analyze-Decompose-Optimize) 方法论流程：

- Analyze (分析)**：在统一实验框架下建立策略基线 (M2)；
- Decompose (分解)**：将验证工具的操作维度拆解为独立可调参数 (M3: method $\times$ candidates $\times$ reduceop)；
- Optimize (优化)**：通过受控消融实验比较各参数变化对应的结果差异，选择本组实验结果较好的参数组合 (kfsb_candidates5)。

该方法的通用性在于：它不依赖于特定模型或工具的算法细节，仅要求验证工具暴露可配置的参数接口，即可进行系统性优化。

6 工程实现

6.1 代码仓库结构

本项目的代码仓库基于开源项目 [Verified-Intelligence/alpha-beta-CROWN](#) 构建。项目实验配置和文档位于 项目书/ 和 complete_verifier/exp_configs/course/ 两个目录，与验证器核心代码明确隔离。

```

1  alpha-beta-CROWN/                # Git 仓库根目录
2  |
3  |— complete_verifier/            # 验证引擎核心
4  |   |— abcrown.py                # 入口: python abcrown.py --config
   |   <yaml>
5  |   |— bab.py                    # BaB 主循环: general_bab()
6  |   |— beta_CROWN_solver.py      # LiRPA: PyTorch → auto_LiRPA 包装
7  |   |— heuristics/               # 分支策略 (babsr.py, kfsb.py, fsb.py)
8  |   |— attack/                   # PGD 攻击实现
9  |   |— exp_configs/course/       # 课程实验配置 (46 YAML 文件)
10 |   |   |— m3/ (5 消融配置)
11 |   |   |— m4/ (12  $\epsilon$ 网格配置)
12 |   |   |— m5_pgd/ (8 PGD配置)
13 |   |   |— m6_incomplete/ (8 不完整验证配置)
14 |   |   |— m7_cifar10/ (4 CIFAR配置)
15 |   |   |— m8_paper_repro/ (5 论文复现配置)
16 |   |— models/                   # ~50 预定义模型架构
17 |
18 |— auto_LiRPA/                   # 边界传播库 (需手动初始化)
19 |
20 |— saved_models/                 # 预训练模型权重
21 |   |— mnist_fcnn.onnx           # 主实验目标模型 (ONNX)
22 |   |— mnist_fcnn.pth            # PyTorch 权重
23 |
24 |— train_mnist_fcnn.py           # 模型训练脚本
25 |
26 |— 项目书/                       # 全部项目文档与实验产出
27 |   |— scripts/                  # 实验脚本 (当前目录 20 个文件)
28 |   |   |— run_m2_strategy_compare.sh # M2 一键复现
29 |   |   |— run_m3_branching_ablation.sh # M3 一键复现
30 |   |   |— run_m4_epsilon_grid.sh    # M4 一键复现
31 |   |   |— run_m5_pgd_compare.sh     # M5 一键复现
32 |   |   |— summarize_m*.py           # 日志→CSV 解析器 (7 个)
33 |   |   |— plot_m*.py                # CSV→PNG 绘图 (3 个)
34 |   |   |— m8_marabou_verify_*.py    # Marabou 集成脚本 (5 个)
35 |   |
36 |   |— results/                   # 全部实验产出
37 |   |   |— m2/                   # M2 基线对比 (CSV + 图)
38 |   |   |— m3/                   # M3 消融 (CSV + 日志 + 图 + meta)
39 |   |   |— m4/                   # M4  $\epsilon$ 网格 (CSV + 日志 + 分片日志 + 图)
40 |   |   |— m5/                   # M5 CIFAR-10 BaB (CSV + 日志)
41 |   |   |— m5_pgd/               # M5 PGD评估 (CSV + 日志 + 报告)
42 |   |   |— m5_pgd_control/       # M5 PGD对照 (CSV)
43 |   |   |— m6_incomplete/        # M6 不完整验证 (CSV + 日志 + 报告)
44 |   |   |— m7_cifar10/           # M7 CIFAR-10 (CSV + 日志 + 报告)
45 |   |   |— m8_marabou/           # M8 Marabou (CSV × 3 + JSON + 报告 ×
3)
46 |   |   |— 完成情况汇报.pptx      # 答辩 PPT (84KB)
47 |   |   |— M2_M3_M4_最终结论表.md # 核心结论汇总
48 |   |
49 |   |— 最终汇报_实验分析与结论.md # 答辩核心文稿 (714行)
50 |   |— 项目全景梳理文档.md        # 非专业人士入门 (772行)
51 |   |— 开题报告.md                # 初始设计
52 |   |— 开题报告vs当前进展对比.md  # 逐条验收对照
53 |   |— 题目要求vs当前进展_对照与评分.md # 10项评分点自查
54 |
55 |— data/                          # MNIST/CIFAR-10 原始数据

```

56	— vnncomp_benchmarks/	# VNN-COMP 标准 benchmark
57	— README.md	# 项目主页 (430行, 中英双语)

仓库统计:

- 课程文件: 46 个 YAML 配置、20 个脚本、13 个 CSV 结果文件、8 张图表, 并配套多份 Markdown 报告, 形成可复现实验证据链

6.2 复现流程

6.2.1 环境配置

```
1 # 1. 克隆仓库
2 git clone --recursive https://github.com/zbhzbhzbh11/alpha-beta-CROWN.git
3 cd alpha-beta-CROWN
4
5 # 2. 创建 Conda 环境
6 conda create -n abcrown python=3.10
7 conda activate abcrown
8
9 # 3. 安装 PyTorch (CUDA 11.8)
10 pip install torch==2.4.1 torchvision==0.19.1 --index-url
    https://download.pytorch.org/whl/cu118
11
12 # 4. 安装 auto_LiRPA 子模块
13 cd auto_LiRPA && pip install -e . && cd ..
14
15 # 5. 安装其余依赖
16 pip install -r complete_verifier/requirements.txt
```

6.2.2 实验复现命令

```
1 cd 项目书/scripts
2
3 # M2 基线策略对比
4 bash run_m2_strategy_compare.sh
5
6 # M3 分支策略消融
7 bash run_m3_branching_ablation.sh
8
9 # M4  $\epsilon$  网格扫描
10 bash run_m4_epsilon_grid.sh
11
12 # M5 PGD 攻击评估
13 bash run_m5_pgd_compare.sh
14
15 # 结果汇总与可视化
16 python summarize_m2_results.py && python plot_m2_results.py
17 python summarize_m3_results.py && python plot_m3_results.py
18 python summarize_m4_results.py && python plot_m4_results.py
19 python summarize_m5_pgd_results.py
```

注意事项:

1. `auto_LiRPA/` 为 Git 子模块, 需手动执行 `git submodule update --init` 或上述 `pip install -e .` 步骤;

2. Shell 脚本中部分路径使用本地绝对路径，在其他机器上复现时需替换为仓库根目录的相对路径；
3. 实验需要 NVIDIA GPU（已在 RTX 4060 Laptop 上测试通过）；
4. $\epsilon=0.05$ 的分片实验需额外配置，详见 [run_m4_epsilon_grid.sh](#) 脚本注释；
5. M8 Marabou 对比需要独立安装 Marabou 环境（WSL Ubuntu + micromamba），详见 [Marabou_WSL安装报告.md](#)。

7 结论

7.1 主要贡献

1. **构建了完整的验证策略梯度光谱**：在统一的 α, β -CROWN 实验框架下，系统评估了 CROWN (0.2s, 不完备)、 α -CROWN (0.7s, 不完备但更紧)、PGD (秒级, 只能找反例)、BaB-babsr/auto/kfsb (约 3–6s, 理论完备但受 timeout 限制) 和 PGD+BaB 联合 (约 2.8–4.6s, 理论完备并结合 PGD 预筛, 但受 timeout 限制) 共 6 种验证方法，明确了各自的能力边界与适用场景；
2. **提出 ADO 方法论并验证其有效性**：通过 Analyze-Decompose-Optimize 三步法，在 method $\times$ candidates $\times$ reduceop 三个维度上比较了各配置参数变化对应的实验结果。核心结论：method 切换 (babsr $\rightarrow$ kfsb) 贡献 VRA +1.0pp, candidates 减少 (10 $\rightarrow$ 5) 额外贡献 +1.0pp, reduceop 影响最小。本组最佳配置 kfsb_candidates5 在 $\epsilon=0.02$ 下实现 VRA 93.0% (+2.0pp vs baseline), timeout -2, mean_time -0.81s；
3. **建立了按 ϵ 分区的策略推荐方案**：通过 3 策略 $\times$ 4 ϵ 的完整网格实验 (M4)，比较了不同扰动半径下的策略表现，并形成限定于本实验设置的工程建议—— $\epsilon \leq 0.01$ 直接用 CROWN； $\epsilon=0.02-0.03$ 用 BaB-kfsb； $\epsilon \geq 0.05$ 可优先采用 PGD 预筛选；
4. **完成跨数据集与跨工具的独立验证**：CIFAR-10 (M7) 验证了 ConvNet 的边界传播松弛远严重于 FCNN 的已知理论预期；Marabou (M8) 作为小样本外部对照，未观察到 safe/unsafe 矛盾判定，并量化了两种技术路线在低扰动样本上的速度差异 ($\epsilon=0.01$ 时约 8.9 $\times$)。

7.2 不足与局限

1. **CIFAR-10 实验规模有限**：本文仅完成 20 个样本的最小可行性验证，未进一步开展与 MNIST 同等规模的分支策略消融和 ϵ 网格实验。后续可在更高算力条件下扩展样本规模，并引入更强的初始化边界方法进行补充验证。
2. **Marabou 对照规模有限**：本文仅选取 5 个样本开展跨工具对照，实验目的主要是验证不同技术路线下是否存在明显矛盾判定，而非进行统计显著性分析。后续可进一步扩展样本规模以获得更稳定的量化结论。
3. **改进层次为配置级优化**：本文的改进主要属于配置级优化，重点在于对现有验证工具进行系统性实验评估与参数消融，而非提出新的验证算法。
4. **路径硬编码问题**：部分实验脚本在原始版本中使用本地绝对路径，跨环境复现时需将其替换为仓库根目录的相对路径。
5. **Gurobi MIP 精化未使用**：验证器支持 Gurobi LP/MIP 求解器精化，但因需要商业 license 未在实验中使用。本文未评估 MIP 精化对 VRA 和计算开销的实际影响；
6. **仅覆盖 L^∞ 范数**：本文所有实验使用 L^∞ 扰动范数。 L_1 、 L_2 等常见威胁模型未覆盖，原因是 α, β -CROWN 对 L^∞ 支持最为成熟，本文未对 L_1 、 L_2 威胁模型开展对比实验。
7. **single-target 验证**：当前验证方法逐个检查每个类别的目标标签（共 9 个 target）。多目标联合验证的效率更高，但实现更复杂，本文未对此开展实验。

参考文献

- [1] SZEGEDY C, ZAREMBA W, SUTSKEVER I, et al. Intriguing properties of neural networks[C]//Proc. of the International Conference on Learning Representations. 2014.

- [2] GOODFELLOW I J, SHLENS J, SZEGEDY C. Explaining and harnessing adversarial examples[C]//Proc. of the International Conference on Learning Representations. 2015.
- [3] HUANG X, KWIATKOWSKA M, WANG S, et al. Safety verification of deep neural networks[C]//Proc. of the Computer Aided Verification (CAV). Cham: Springer, 2017: 3-29.
- [4] KATZ G, HUANG D A, IBELING D, et al. The Marabou framework for verification and analysis of deep neural networks[C]//Proc. of the Computer Aided Verification (CAV). Cham: Springer, 2019: 443-452.
- [5] BUNEL R, TURKASLAN I, TORR P H S, et al. A unified view of piecewise linear neural network verification[C]//Proc. of the Advances in Neural Information Processing Systems (NeurIPS). 2018.
- [6] BAK S, LIU C, JOHNSON T T. The 2nd International Verification of Neural Networks Competition (VNN-COMP 2021): Summary and results[J]. arXiv preprint arXiv:2109.00498, 2021.
- [7] ZHANG H, WENG T W, CHEN P Y, et al. Efficient neural network robustness certification with general activation functions[C]//Proc. of the Advances in Neural Information Processing Systems (NeurIPS). 2018.
- [8] XU K, ZHANG H, WANG S, et al. Fast and complete: Enabling complete neural network verification with rapid and massively parallel incomplete verifiers[C]//Proc. of the International Conference on Learning Representations (ICLR). 2021.
- [9] WANG S, ZHANG H, XU K, et al. Beta-CROWN: Efficient bound propagation with per-neuron split constraints for complete and incomplete neural network verification[C]//Proc. of the Advances in Neural Information Processing Systems (NeurIPS). 2021.
- [10] BUNEL R, DE PALMA A, DESMAISON A, et al. Lagrangian decomposition for neural network verification[C]//Proc. of the Conference on Uncertainty in Artificial Intelligence (UAI). 2020.

附录 A 实验证据链索引

表18 实验证据链索引

实验	CSV 数据源	日志目录	配置目录	图表
M2	m2_strategy_compare_0_100.csv	实验日志/	mnist_baseline_*.yaml	m2/figures/ (2 张)
M3	m3_branching_ablation.csv + m3_nodes_summary.csv	m3/logs/ (5 个)	m3/ (5 YAML)	m3/figures/ (3 张)
M4	m4_epsilon_grid.csv	m4/logs/ (12 个) + chunks/ (30 个)	m4/ (12 YAML)	m4/figures/ (3 张)
M5 PGD	m5_pgd_compare.csv	m5_pgd/logs/ (8 个)	m5_pgd/ (8 YAML)	—
M5 CIFAR	m5_cifar10_compare.csv	m5/logs/ (2 个)	(已有配置)	—
M6	m6_incomplete_compare.csv	m6_incomplete/logs/ (14 个)	m6_incomplete/ (8 YAML)	—
M7	m7_cifar10_incomplete.csv	m7_cifar10/logs/ (4 个)	m7_cifar10/ (4 YAML)	—
M8	m8_marabou_5samples_eps*.csv (3 个)	m8_marabou/logs/ (2 个)	m8_marabou_compare.yaml	—

附录 B Git 提交历史摘要

表19 Git 提交历史摘要

Commit	日期	说明
c185cc0	2026-05-24	更新 README：补充 M8 Marabou 对比 + 论文复现章节
b7e9e45	2026-05-24	M8：Marabou 跨工具对比 + ADO 方法论 + 完成情况汇报 PPT
36b6440	2026-05-04	完善 README：覆盖 M2-M7 全部实验里程碑
643c4ae	2026-05-04	M2/M3/M4/M5/M6/M7：完整实验结果、配置、脚本与文档
79d9ed9	2026-04-10	完成 README 初稿
16b6ae0	2026-04-10	添加项目 README、完成情况汇报 PPT
1306d4d	2026-04-04	完成项目书（开题报告、全景文档、实验方案）

项目开发时间线：04-04 项目书与实验方案 → 04-10 README 与 PPT 初稿 → 05-04 M2-M7 全部数据交付 → 05-24 M8 Marabou 收口与终稿。